

Türkçe Çok Anlamlı Kelimeler Üzerinde Contextual Embedding ve BERT Karşılaştırması

Ahmetcan PEKTAŞ

Bilgisayar Mühendisliği Ana Bilim Dalı YL, Mühendislik Fakültesi, Bandırma Onyedi Eylül Üniversitesi, Balıkesir, Türkiye
ahmetcanpektas@ogr.bandirma.edu.tr

Uygulama kod ve çıktılarına sağ üstteki github linkinden ulaşabilirsiniz.

Tarih: 05.05.2026

Özet: Bu çalışma, dbmdz/bert-base-turkish-cased modelinin dört Türkçe çok anlamlı kelime üzerindeki bağlamsal gömme (embedding) davranışını analiz etmektedir. CLS düzeyinde kosinüs benzerlikleri 0.8179 ile 0.9497 arasında değişmiş ve bu durum BERT'ün bağlama duyarlı temsiller üretebildiğini göstermiştir. Bir Maskeli Dil Modeli (MLM) deneyi, bağlamsal anlam ayrımını doğrulamıştır. Aşağı akış (downstream) görevinde yapılan deneyler, ince ayar (fine-tuning) yapılmadan kullanılan BERT modelinin rastgele düzeyde tahminler ürettiğini; buna karşılık ince ayar yapılmış modelin aynı girdiler üzerinde %98'in üzerinde güvenle doğru tahminler yapabildiğini ortaya koymuştur.

Anahtar Kelimeler: BERT, Contextual Embedding, Maskeli Dil Modeli (MLM), Fine-tuning, Türkçe Doğal Dil İşleme, Kosinüs Benzerliği

Türkçe Çok Anlamlı Kelimeler Üzerinde Contextual Embedding ve BERT Karşılaştırması

1. Contextual Embedding Analizi

Bu bölümde dbmdz/bert-base-turkish-cased modeli ile dört çok anlamlı Türkçe kelime (banka, kol, yüz, dil) için ikiye farklı anlam içeren cümle yazılmıştır. Her cümledeki CLS token embedding'i çıkarılarak aralarındaki cosine similarity değerleri hesaplanmıştır. Sonuçlar aşağıdaki tabloda özetlenmektedir.

Tablo 1. Cosine Similarity Sonuçları

Kelime	Cümle 1 (Anlam 1)	Cümle 2 (Anlam 2)	Cos. Sim.
banka	Bankaların faiz kararları küresel ekonomiyi hatırlatır. (Finans kurumu)	Parktaki banka oturan amcanın yanına gittim ve güzel bir sohbet ettik. (Oturma sırası)	0.9497
kol	Dün o kadar çok sınav çektim ki kollarımın dermanı kalmadı. (Vücut uzvu)	Türkçe, geleneksel olarak Ural-Altay dil ailesinin Altay kolunda sınıflandırılmıştır. (Örgüt/dal)	0.8179
yüz	Odadaki insanların yüzlerinde derin bir endişe hakimdi. (Surat)	Hava tahmini raporlarındaki yüzde yüz ifadesi bölgenin yüzey alanını ifade eder. (Sayı 100)	0.8900
dil	Dilim o kadar hassas ki ne zaman sıcak bir şeyler içsem hemen yanar. (Konuşma organı)	Görüntü işleme ve veri bilimi projelerinde ağırlıklı olarak Python programlama dili kullanılır. (Programlama dili)	0.9488

Sonuçlara göre en belirgin anlamsal ayrışma kol kelimesinde (0.8179) gözlenmiştir. Banka (0.9497) ve dil (0.9488) için daha yüksek değerler, [CLS] token'ının cümleyi özetleyici yapısından kaynaklanmaktadır. Statik modellerin aksine (ör. Word2Vec), elde edilen 0.82–0.95 aralığı, BERT'in bağlama duyarlı temsil üretebildiğini göstermektedir. Bu durum, self-attention mekanizması sayesinde aynı kelimenin farklı bağlamlarda farklı vektörlerle temsil edilmesiyle açıklanır.

2. BERT Model Analizi (MLM)

Fill-mask yöntemiyle yapılan testlerde, BERT modelinin bağlama duyarlı tahminler ürettiği gözlemlenmiştir. “Ali bankaya gitti çünkü [MASK] yatacağı” cümlesinde model sırasıyla parayı (%23.1), para (%18.2), parasını (%8.3) tahminlerini üretmiş; Top-5 sonuçların tamamı finans bağlamıyla uyumlu çıkmıştır. Buna karşılık, “Nehir kenarındaki bankaya [MASK] oturdu” cümlesinde gidip (%27.2) ve geçip (%6.5) gibi hareket fiilleri öne çıkmış, finansla ilgili herhangi bir tahmin üst sıralarda yer almamıştır. “Doktor hastayı muayene etti çünkü [MASK] hasta idi” örneğinde ise hasta (%38.7), o (%14.3) ve kendisi (%10.6) tahminleri elde edilmiştir. Bu bulgular, modelin gerçek dünya bilgisinden ziyade istatistiksel dil kalıplarına dayandığını; ancak bağlam sinyalinin güçlü olduğu durumlarda yüksek olasılıklı ve tutarlı tahminler üretebildiğini göstermektedir.

3. Limitasyon Analizi: Ham BERT ile Duygu Analizi Denemesi ve Fine-Tuning

Ham dbmdz/bert-base-turkish-cased modeline doğrudan metin sınıflandırma görevi verildiğinde teknik olarak hata oluşmamış; ancak çıktılar anlamsal açıdan yetersiz kalmıştır. “Bu film harikaydı” ve “Bu film çok kötüydü” cümlelerinin her ikisi de LABEL_0 etiketiyle, sırasıyla 0.6624 ve 0.6720 skorlarıyla sınıflandırılmıştır. Bu değerler, rastgele tahmin düzeyi (~0.50) ile kıyaslandığında yalnızca sınırlı bir artış göstermekte ve anlamlı bir duygu ayrımı sunmamaktadır.

Bu durum, model mimarisiyle doğrudan ilişkilidir. Yükleme sırasında görülen classifier.weight | MISSING ve classifier.bias | MISSING uyarıları, modelde eğitilmiş bir sınıflandırma başlığının bulunmadığını göstermektedir. Hugging Face Transformers kütüphanesi bu katmanı rastgele başlatarak çalıştırır da, bu ağırlıklar eğitilmediği için çıktılar anlamsal bilgi içermez. BERT, son katmanda [CLS] token’ına ait 768 boyutlu bir vektör üretir; ancak bu vektörü etiketlere dönüştüren nn.Linear(768, 2) katmanı eğitilmeden duygu analizi yapılması mümkün değildir.

Fine-tuning karşılaştırması: Aynı cümleler savasy/bert-base-turkish-sentiment-cased modeline verildiğinde, pozitif cümle 0.9838, negatif cümle ise 0.9934 güven skoru ile doğru şekilde sınıflandırılmıştır. İki model aynı BERT tabanını paylaşmasına rağmen, bu fark yalnızca etiketli veri ile yapılan ince ayar (fine-tuning) sürecinden kaynaklanmaktadır. Bu sonuç, önceden öğrenilmiş dil temsillerinin, göreve özgü eğitimle yüksek doğrulukta çıktılara dönüştürülebileceğini açık biçimde göstermektedir.

4. Kavramsal Hazırlık

Fine-tuning: Önceden eğitilmiş bir modelin belirli bir görev için yeniden uyarlanmasıdır. Bu süreçte modele göreve özgü bir çıkış katmanı eklenir ve etiketli veriyle ek eğitim yapılır. Böylece model, genel dil bilgisini korurken hedef göreve uygun davranmayı öğrenir; ayrıca sıfırdan eğitime kıyasla çok daha az veri ve hesaplama gerektirir.

Pre-trained Model: Geniş ve genel veri kümeleri üzerinde öz-denetimli yöntemlerle eğitilmiş, parametreleri hazır modeldir. dbmdz/bert-base-turkish-cased bu kapsamda Türkçe metinler üzerinde MLM ile eğitilmiş olup, farklı görevler için güçlü bir başlangıç noktası sunar.

Downstream Task: Ön-eğitilmiş modelin üzerine inşa edilen uygulama görevlerini ifade eder. Duygu analizi, adlandırılmış varlık tanıma ve soru-cevaplama gibi görevler bu kategoriye girer. Bu yaklaşım, modelin önceden öğrendiği dil bilgisinden yararlanarak daha az veriyle etkili sonuçlar elde edilmesini sağlar.

Classification vs Token-level Task: Sınıflandırma görevlerinde model, tüm cümle için tek bir etiket üretir ve genellikle [CLS] vektörü kullanılır (örneğin duygu analizi). Buna karşılık token-level görevlerde her bir kelime için ayrı etiket tahmin edilir ve her token’ın çıktı vektörü değerlendirilir (örneğin NER veya POS tagging). Her iki görev türü de aynı BERT mimarisini kullanır; temel fark, çıkış katmanının yapısında ortaya çıkar.

5.Sonuç

Bu çalışma, BERT modelinin statik modellere kıyasla bağlama duyarlı anlam ayrımı yapabildiğini deneysel olarak ortaya koymuştur. Özellikle çok anlamlı kelimeler üzerinde elde edilen bulgular, klasik yaklaşımlarda gözlenen anlam ayrımı sınırlılıklarının aşıldığını göstermektedir. Bununla birlikte, fine-tuning uygulanmadan downstream görevlerde anlamlı sonuçlar elde edilemeyeceği açık biçimde görülmüştür. Aynı girdiler üzerinde yapılan karşılaştırmada, ince ayar yapılmış modelin %98’in üzerinde güvenle doğru sınıflandırma üretmesi, fine-tuning sürecinin performans üzerindeki belirleyici etkisini sayısal olarak doğrulamaktadır.